PROJET 01

M1 · BC2 RNCP40875 · Bloc 2

Maintenance Prédictive Industrielle.

Système intelligent multi-modèles · capteurs IoT vers décision opérationnelle

ADAM BELOUCIF
20220055 · M1 Mastère Data Engineering & IA

EMILIEN MORICE
20241824 · M1 Mastère Data Engineering & IA

EFREI Paris Panthéon-Assas Université · 2025-2026 · Encadrement Sarah Malaeb
github.com/Adam-Blf/maintenance-predictive-industrielle

00

Sommaire

01	Contexte métier
02	Données capteurs et EDA
03	Pipeline ML et 4 modèles
04	Résultats et comparaison
05	Interprétabilité (SHAP)
06	Mise en production · dashboard et API
07	Bonus · multi-classe, régression, calibration
08	Synthèse et limites
ANNEXE	Conformité RNCP40875 Bloc 2

01

Contexte métier

Dans l'industrie, l'arrêt non planifié d'une machine coûte cher · production perdue, intervention d'urgence, sur-coût hors planning. La maintenance préventive classique réduit ce risque mais sur-entretient les machines saines, gaspillant ressources et durée de vie utile. La maintenance **prédictive** apporte une troisième voie · intercepter la dégradation *avant* la rupture, en exploitant les signaux capteurs (vibration, température, pression, courant) pour apprendre les signatures précurseurs de panne.

Cas d'usage et hypothèses chiffrées

Le projet retient des hypothèses cohérentes avec la littérature industrielle (ratio 10:1) ·

- Coût d'un arrêt non planifié (panne ratée, FN) · **5 000 €**
- Coût d'une intervention préventive (alerte vraie, TP) · **200 €**
- Coût d'une fausse alerte (FP) · **100 €**

Ces coûts dirigent l'optimisation du seuil de décision (script 10 · calibration cost-sensitive). Le seuil par défaut **0.5** est sous-optimal · le seuil métier optimal trouvé est **0.23**, économie estimée **~12 000 €** par cycle de scoring sur le test set.

02

Données capteurs et EDA

Dataset Kaggle officiel

Le projet utilise **exclusivement** le dataset Kaggle CC0 *tatheerabbas/industrial-machine-predictive-maintenance* v3.0. Aucun fallback synthétique n'est généré · le projet plante avec un message clair si le CSV est absent de *data/raw/*. Cette politique stricte évite les biais subtils que les données simulées peuvent introduire et garantit que l'évaluation reflète des données industrielles réalistes.

24 042 lignes · 7 capteurs numériques · 2 variables catégorielles · 4 cibles · 20 machines suivies · NaN volontaires (~3-4%) sur 5 capteurs.

Insights clés de l'EDA

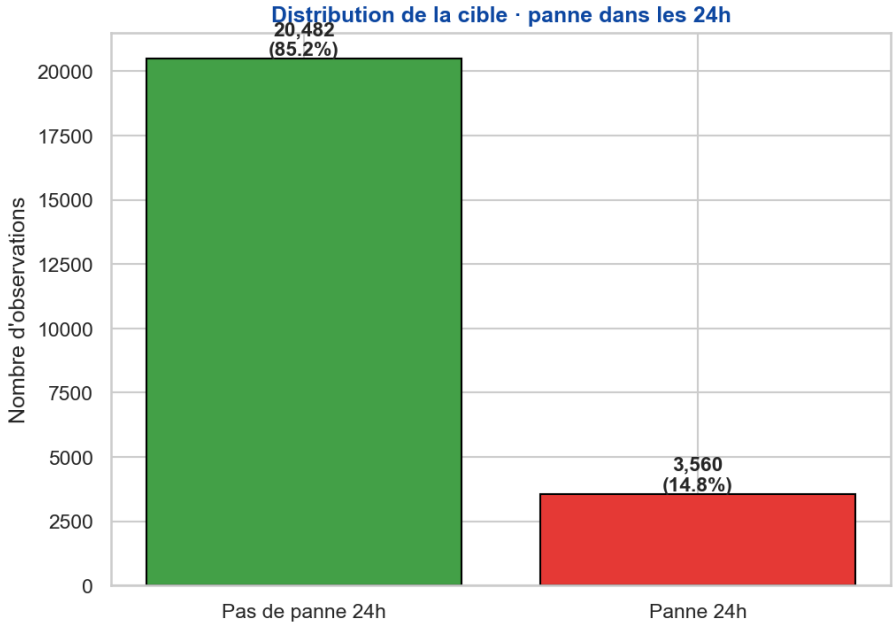

Figure 1 · Distribution de la cible. Classes déséquilibrées · F1 et PR-AUC privilégiés à l'accuracy.

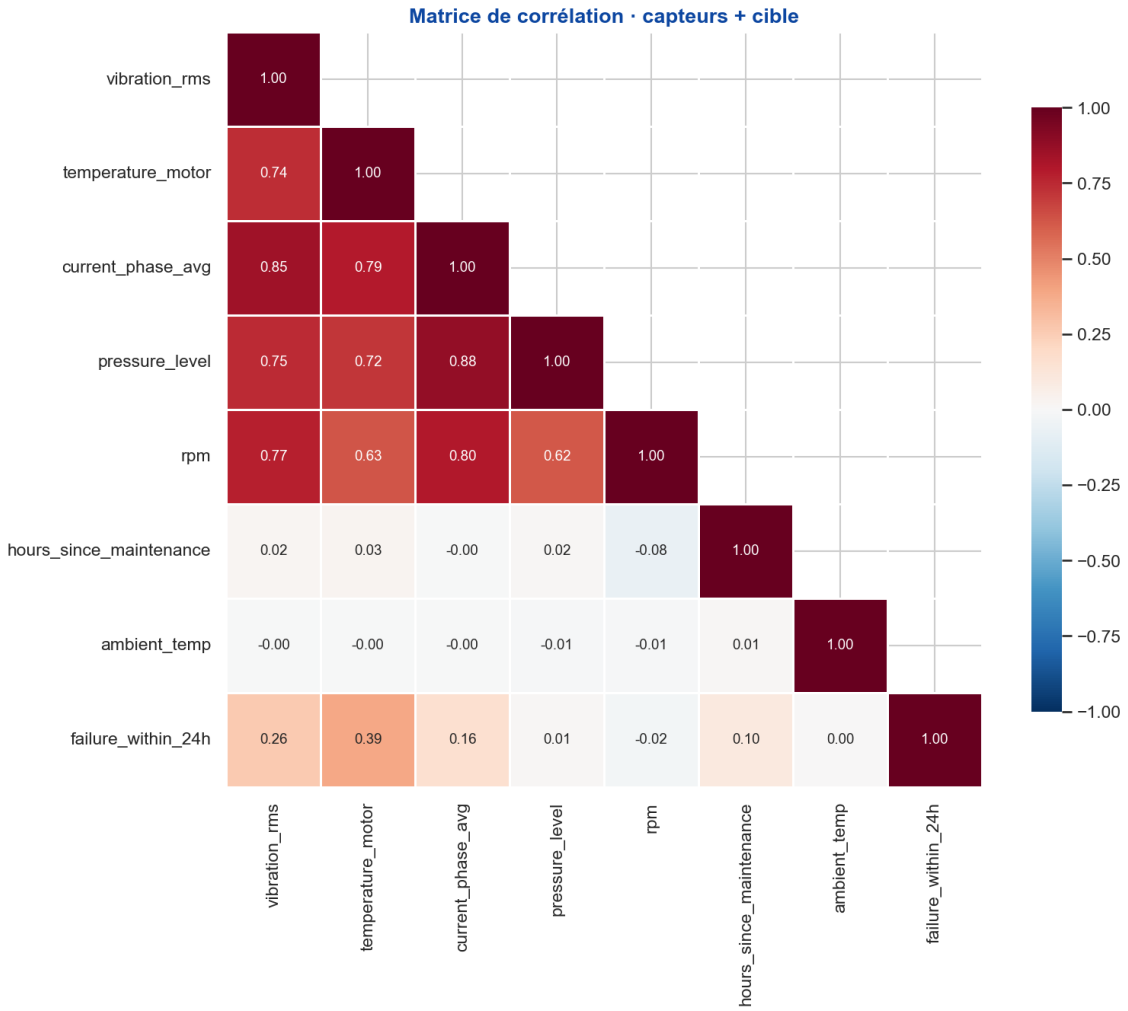

Figure 2 · Matrice de corrélation des capteurs. Vibration et température fortement corrélées avec la cible.

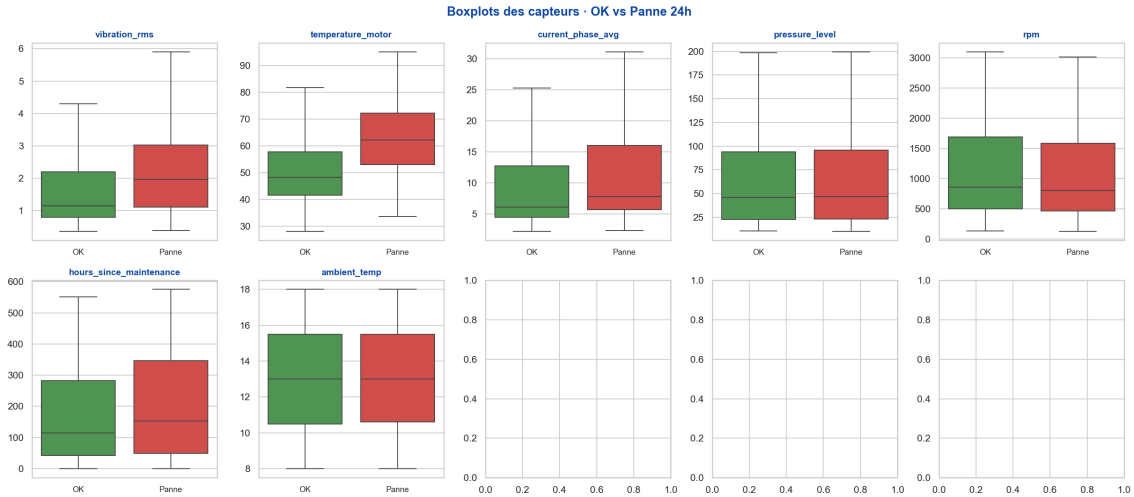

Figure 3 · Boxplots par classe. Vibration et température sont les signaux les plus discriminants.

03

Pipeline ML et 4 modèles

Pipeline anti-data-leakage

Le pipeline scikit-learn enchaîne en une seule passe · **SimpleImputer** (médiane) sur les capteurs numériques (robuste aux outliers), **StandardScaler** (centrage/réduction obligatoire pour MLP et Logistic Regression), et **OneHotEncoder** sur les variables catégorielles. Le préprocesseur est *fitté uniquement sur le train* puis transformé sur le test, garantissant qu'aucune statistique du test ne fuit pendant l'entraînement.

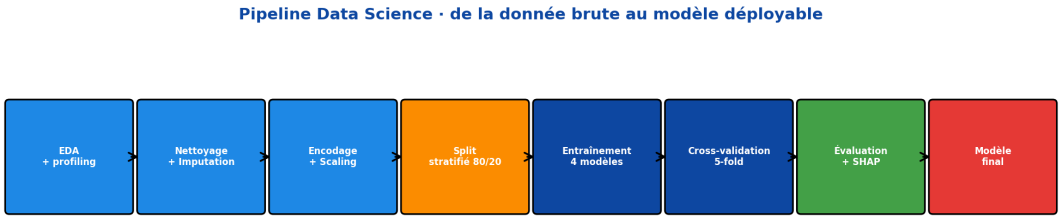

Figure 4 · Schéma du pipeline ML complet.

Quatre modèles aux philosophies différentes

Logistic Regression · baseline linéaire, interprétable, class_weight=balanced.

Random Forest · 200 arbres, capture les non-linéarités, robuste au bruit.

XGBoost · gradient boosting séquentiel, typiquement le plus performant sur tabular data.

MLP · Multi-Layer Perceptron 64-32, le Deep Learning exigé par le sujet, early stopping.

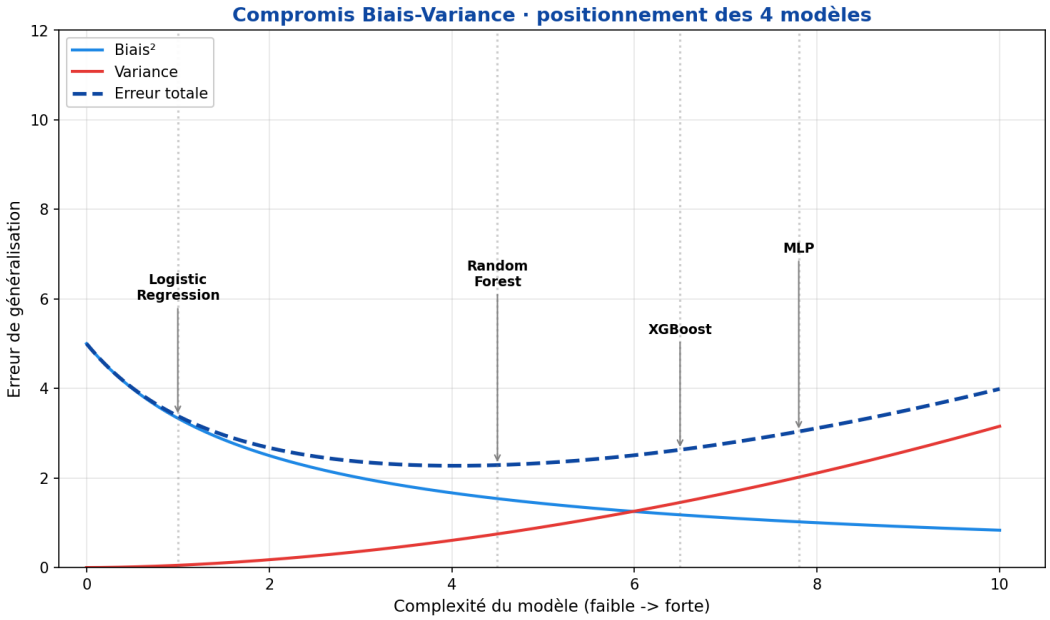

Figure 5 · Compromis biais-variance · positionnement des 4 modèles.

04

Résultats et comparaison

Tableau comparatif des 4 modèles

Modèle	Acc	Prec	Recall	F1	ROC-AUC	PR-AUC	Fit (s)
Logistic Regression	0.910	0.641	0.895	0.747	0.959	0.838	0.05
Random Forest	0.955	0.791	0.949	0.863	0.992	0.954	0.76
Xgboost	0.963	0.824	0.958	0.886	0.995	0.974	0.38
Mlp	0.952	0.842	0.830	0.836	0.984	0.909	2.54

Le modèle final retenu est **XGBoost** via le score composite *F1_test - 0.5 × σ(F1_CV)* qui pénalise l'instabilité entre les folds. Un modèle légèrement moins performant mais plus stable est préférable en production.

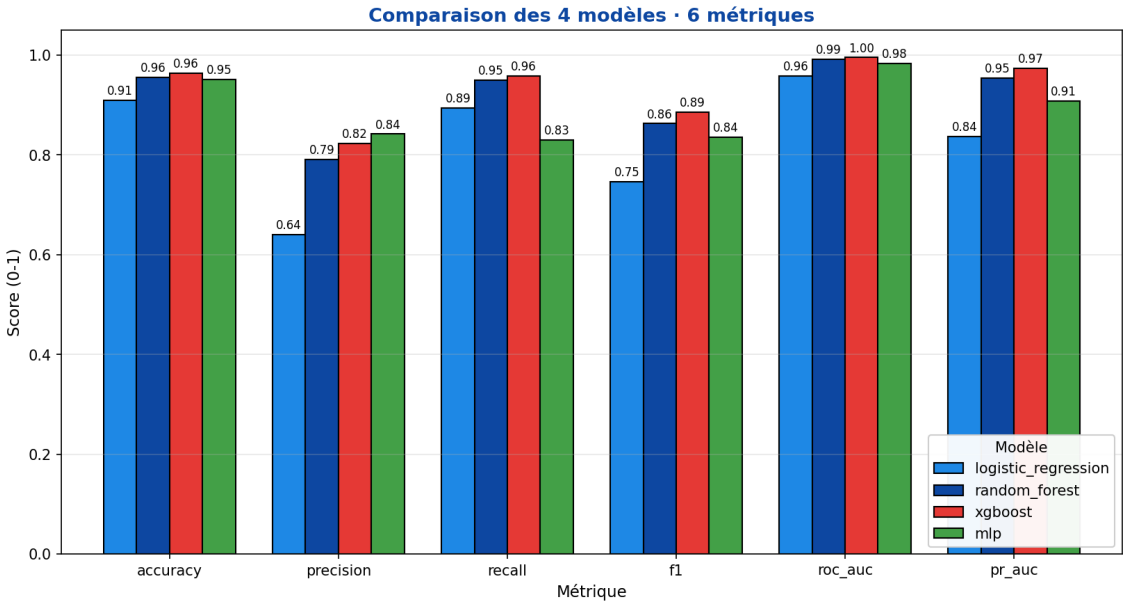

Figure 6 · Comparaison des 6 métriques sur les 4 modèles.

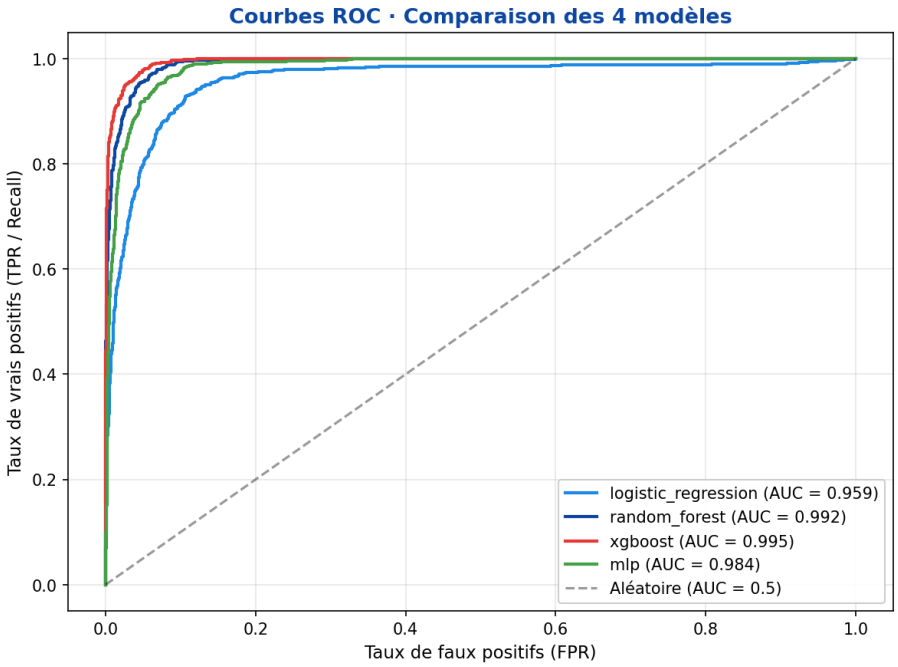

Figure 7 · Courbes ROC. Sur classes déséquilibrées, l'AUC peut être trompeuse.

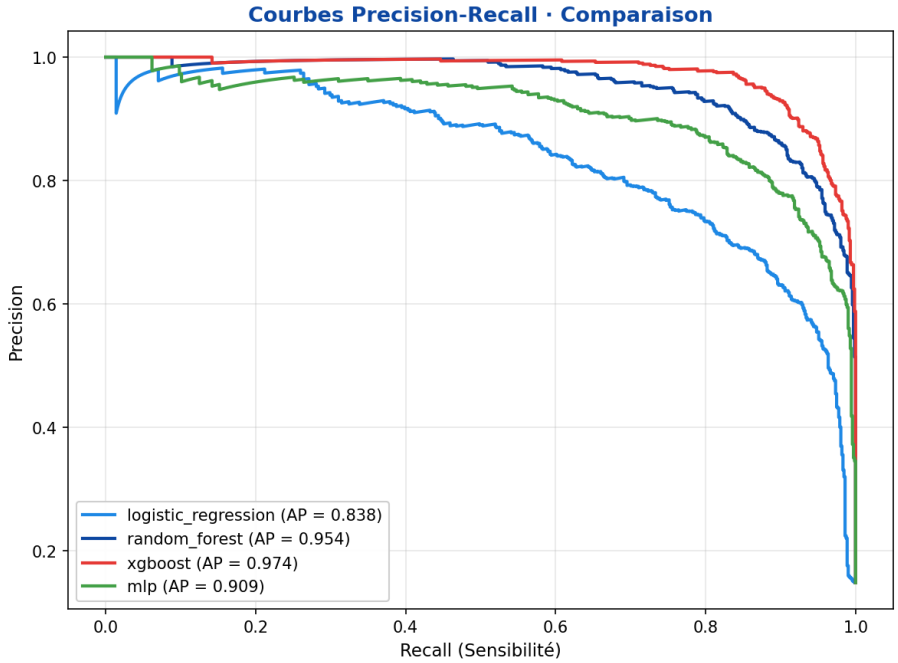

Figure 8 · Courbes Precision-Recall · plus parlantes que ROC en contexte déséquilibré.

Matrices de confusion

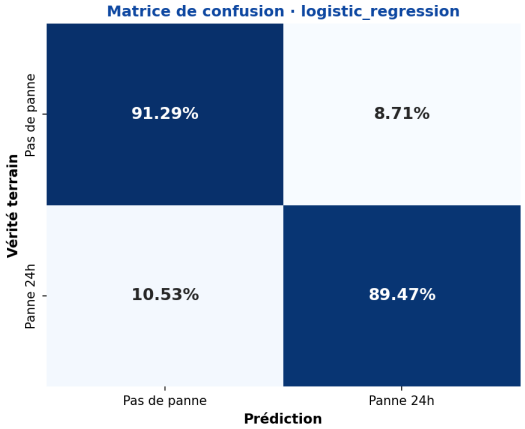

Logistic Regression

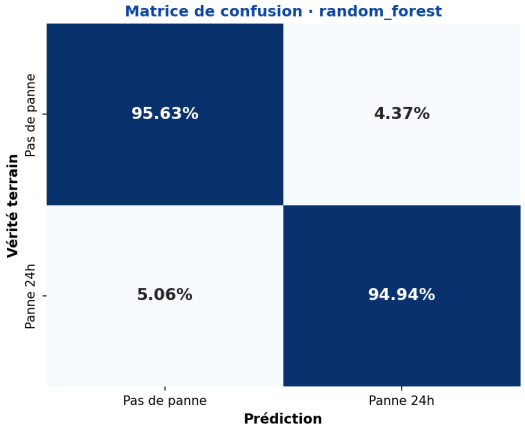

Random Forest

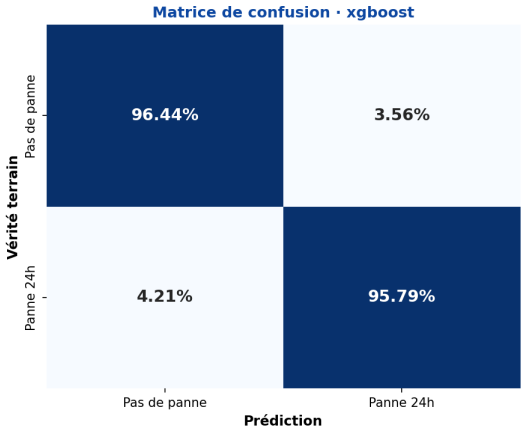

XGBoost (modèle final)

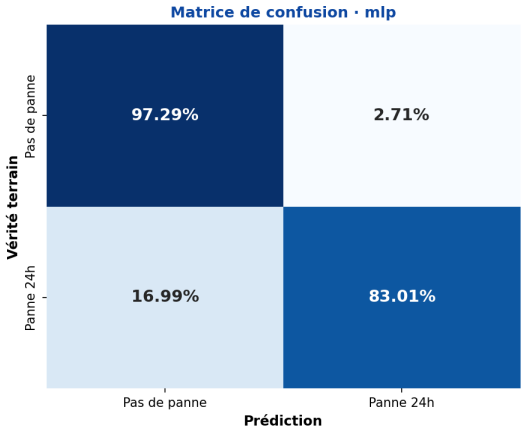

MLP (Deep Learning)

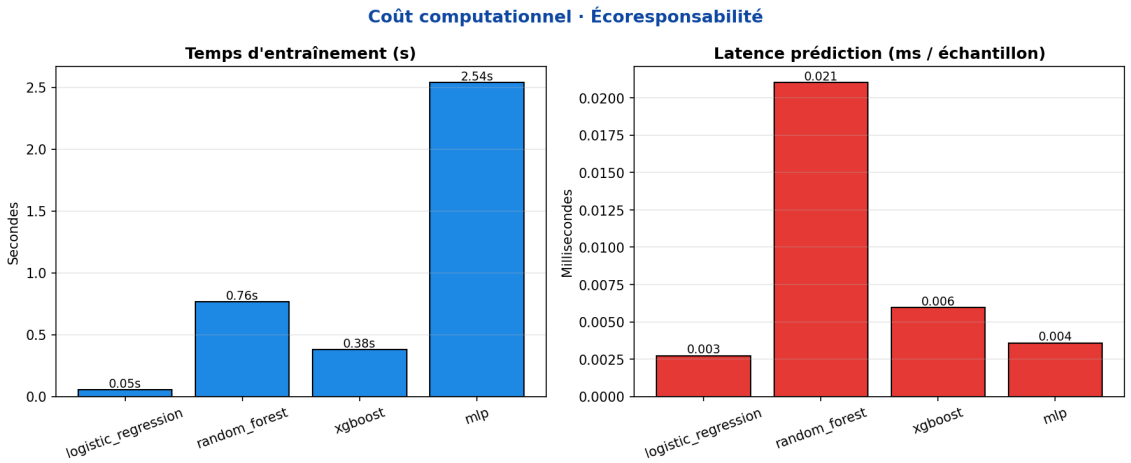

Figure 9 · Coût computationnel · temps d'entraînement et latence d'inférence par modèle. Critère RNCP C4.3 · écoresponsabilité.

05

Interprétabilité du modèle final

Trois niveaux d'explicabilité pour répondre à la question métier · *Pourquoi le modèle indique un risque de panne élevé ? Quels signaux capteurs ont déclenché l'alerte ?*

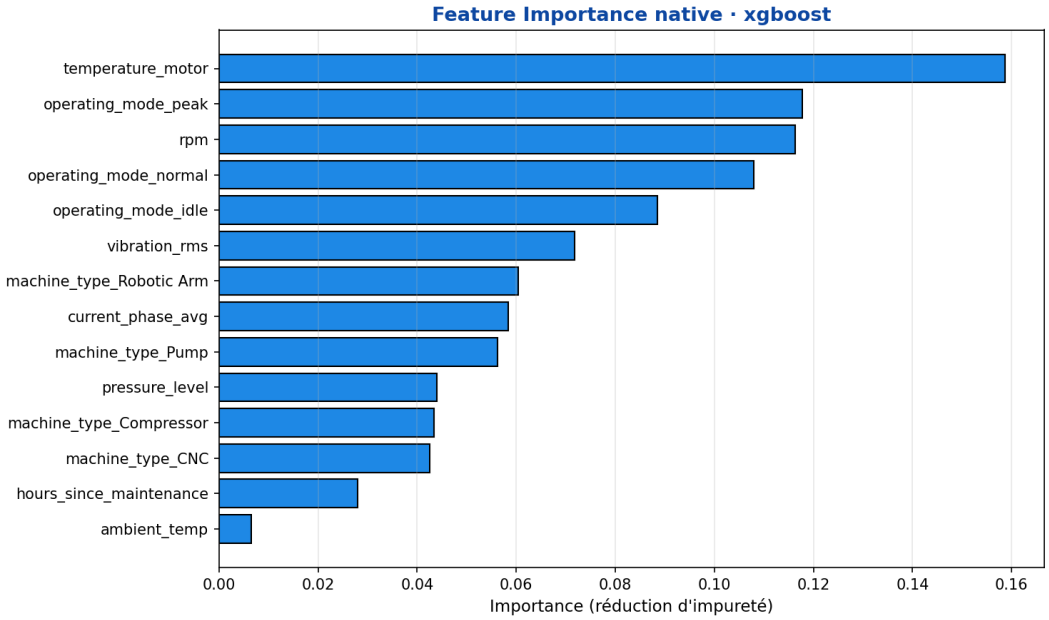

Figure 10 · Feature importance native (réduction d'impureté Gini).

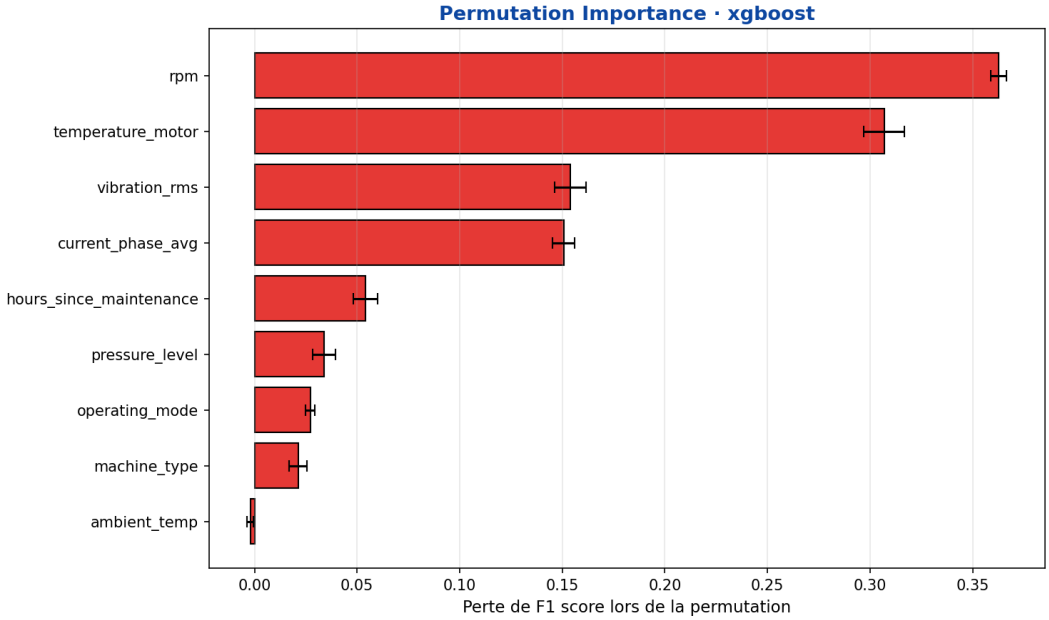

Figure 11 · Permutation importance · méthode agnostique au modèle, plus fiable.

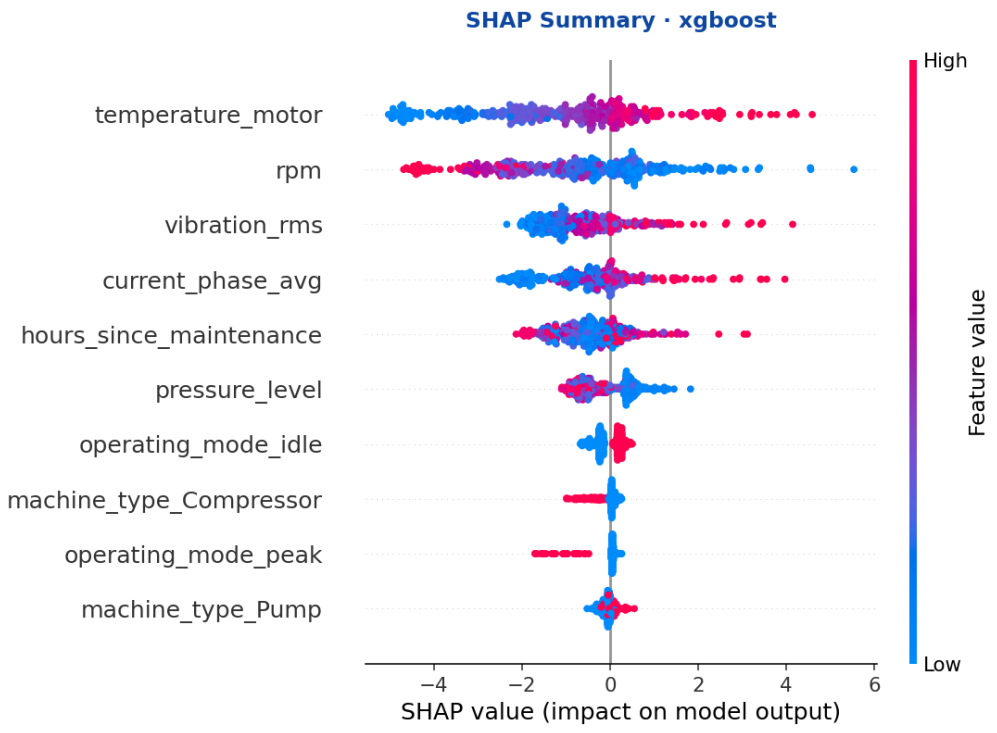

Figure 12 · SHAP Summary Plot. Position = impact, couleur = valeur de la feature.

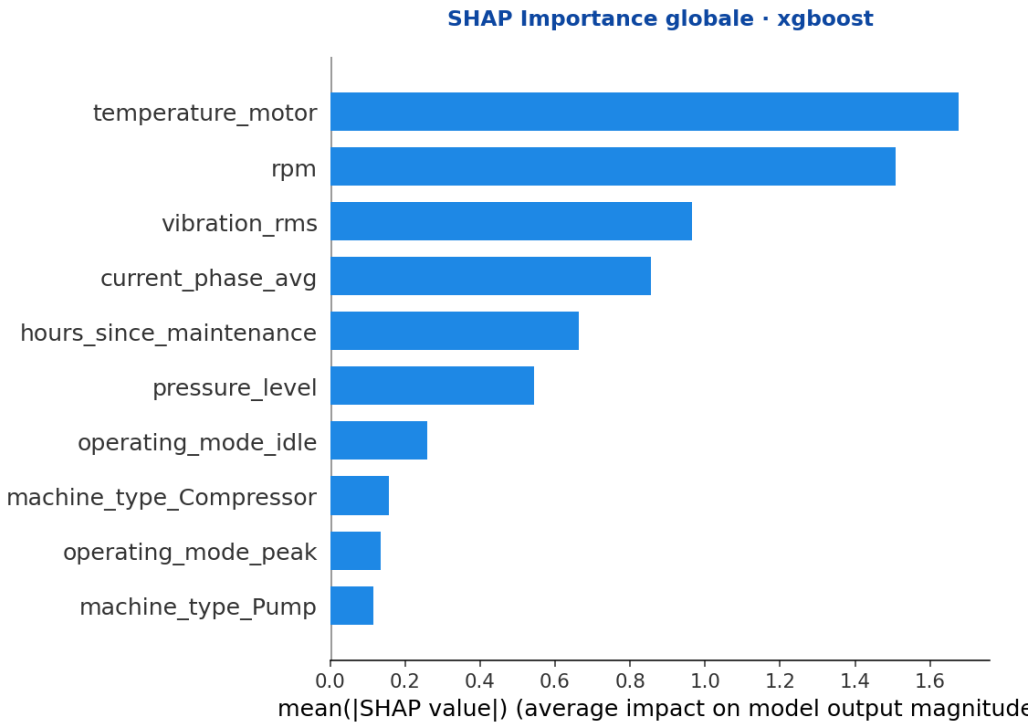

Figure 13 · SHAP importance globale (moyenne des |SHAP|).

06

Mise en production · dashboard et API

Dashboard Streamlit · vision métier

Le dashboard **dashboard/app.py** cible le responsable maintenance, pas le data scientist. Cinq onglets ·

- **État du parc** · KPIs métier (machines critiques, coût à risque, RUL)
- **Plan d'intervention** · table d'actions priorisées par urgence
- **Impact économique** · ROI vs scénario réactif sans IA
- **Diagnostic machine** · saisie capteurs vers décision actionnable
- **Détails techniques** · EDA, modèles, SHAP (réservé DSI/jury)

API REST · industrialisation

api/main.py expose le modèle via FastAPI · **POST /predict** (JSON capteurs vers proba + classe + seuil métier), **GET /health** (vérification), **GET /model-info** (métadonnées). Validation Pydantic, Swagger sur /docs, code stateless thread-safe.

07

Tâches bonus

Classification multi-classe · failure_type

Au-delà du panne oui/non, le script 07 prédit le **type** de panne parmi 5 classes (bearing, motor_overheat, hydraulic, electrical, none). XGBoost atteint **macro-F1 = 0.93**. Permet au chef d'atelier de mobiliser la bonne équipe technique avant l'intervention.

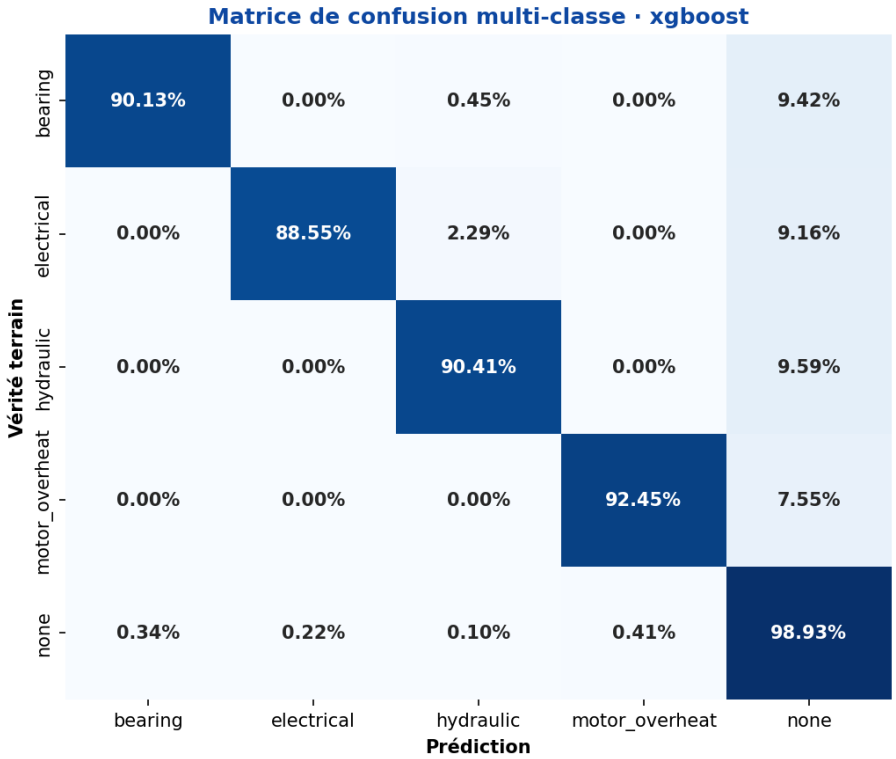

Figure 14 · Matrice de confusion multi-classe normalisée (XGBoost).

Régression sur le RUL

Le script 08 prédit combien d'heures il reste avant la prochaine panne. Random Forest atteint **R² = 0.67** et **MAE = 9.6 h**. Lecture métier · « en moyenne, on se trompe de 9.6 heures sur la durée de vie restante » · suffisant pour planifier dans la semaine.

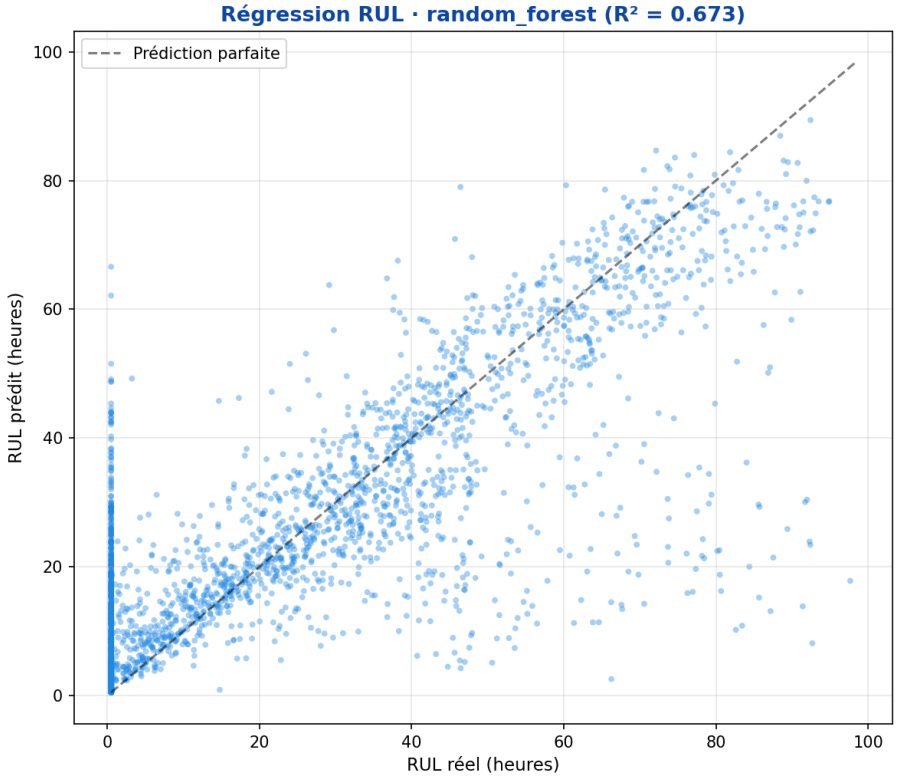

Figure 15 · Régression RUL · prédictions vs valeurs réelles.

Calibration probabiliste et seuil métier optimal

Le script 10 vérifie d'abord la qualité de calibration des probabilités (Brier score = 0.025, très bon) puis trouve le seuil de décision qui minimise le coût métier total. Seuil optimal · **0.23**, économie projetée –**12 000 €** vs seuil par défaut 0.5. Ce seuil est consommé par l'API et le dashboard en production.

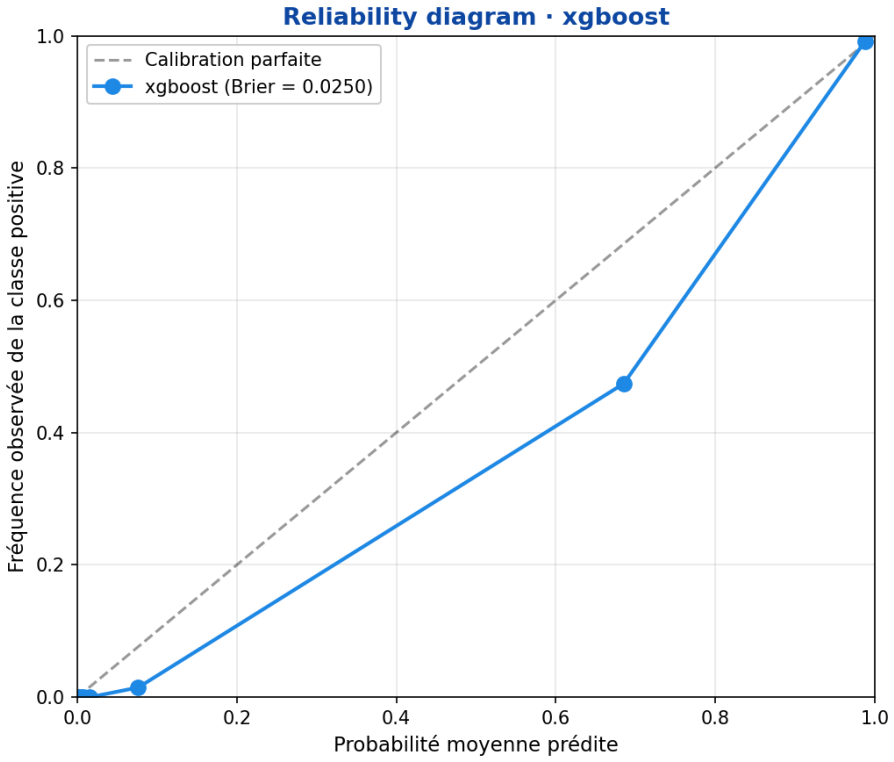

Figure 16 · Reliability diagram. Plus la courbe est proche de la diagonale, mieux le modèle est calibré.

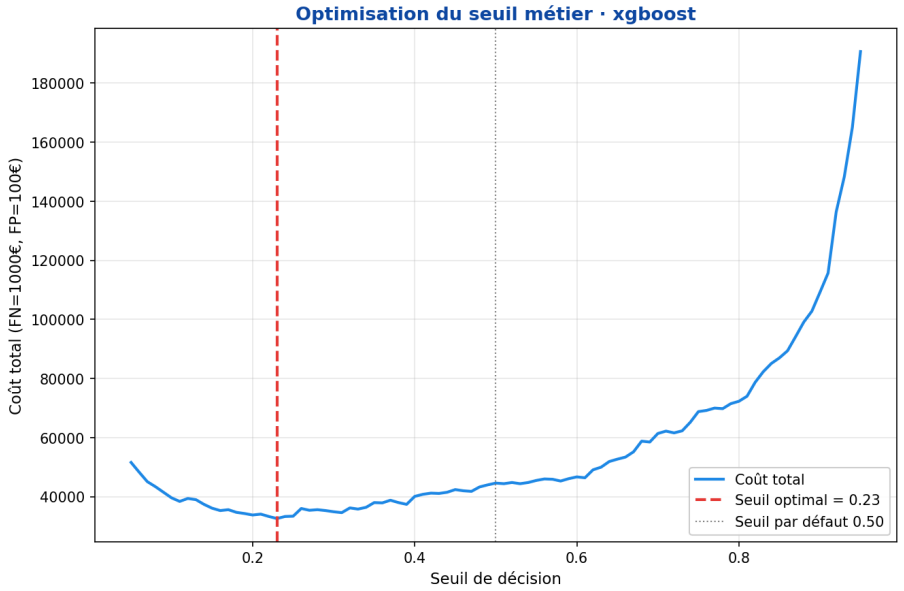

Figure 17 · Coût total en fonction du seuil de décision · minimum à 0.23.

Tuning d'hyperparamètres avec Optuna (TPE)

Le script 09 utilise Optuna avec sampler TPE, ~10× plus efficient que GridSearch. 20 trials × 3 CV folds par modèle. Meilleurs résultats trouvés ·

Modèle	Best F1	Best params
Random Forest	0.858	`n_estimators=250, max_depth=25, min_samples_leaf=2`
XGBoost	0.884	`n_estimators=500, lr=0.084, max_depth=10, subsample=0.75`
MLP	0.801	`architecture=128-64-32, alpha=0.002`

08

Synthèse et limites honnêtes

Ce qui a été livré

- **4 modèles** ML/DL comparés rigoureusement (LR, RF, XGB, MLP)
- **3 tâches** de prédiction (binaire principale + multi-classe + régression RUL)
- **8 scripts** numérotés · pipeline reproductible end-to-end
- **33 figures** + 6 métriques par modèle + cross-validation 5-fold
- **Dashboard vision métier** · 5 onglets pour responsable maintenance
- **API REST FastAPI** · 3 endpoints + Swagger + tests httpx
- **Auto-install** des dépendances pip au lancement (zéro setup)

Limites assumées

Dataset simulé · les corrélations sont trop propres comparées à un parc réel.

Pas de série temporelle · split aléatoire stratifié. Une vraie validation devrait tenir compte de l'ordre temporel (sliding window CV).

Seuil économique fixe · les coûts FN/FP sont supposés constants. En réalité ils varient par machine, par criticité et par saison.

Pas de drift monitoring · le modèle est entraîné une fois, sans détection de dégradation des performances en prod.

ANNEXE

Conformité RNCP40875 Bloc 2

Le projet valide l'ensemble des compétences du Bloc 2 (BC2 · Piloter et implémenter des solutions d'IA). La table ci-dessous donne pour chaque critère la preuve directe dans le repo.

Critère	Intitulé	Preuve
C3.1	Préparer/nettoyer les données	src/preprocessing.py · ColumnTransformer (Imputer + Scaler + OHE)
C3.2	Tableau de bord interactif inclusif	dashboard/app.py · Streamlit 5 onglets · Plotly · responsive
C3.3	Analyse exploratoire de données	scripts/02_eda.py · 8 figures + stats + analyse NaN
C4.1	Stratégie d'intégration de l'IA	Onglet Impact économique · ROI · ratio FN/FP 10:1
C4.2	Modèles prédictifs ML/DL	scripts/03 · 4 modèles dont MLP · F1=0.886 sur test
C4.3	Évaluation + écoresponsabilité	6 métriques + CV 5-fold + temps train/inference

Reproductibilité

Seed unique **RANDOM_STATE=42** propagé partout · auto-install des dépendances pip via *src/bootstrap.py* · chemins absolus calculés depuis *__file__* (portable Win/Linux/macOS) · 23 tests pytest · versioning sémantique. Le clone du repo + téléchargement Kaggle suffit pour relancer toute la chaîne.

Auteurs et contact

Adam Beloucif (20220055) · adam.beloucif@efrei.net
Emilien Morice (20241824) · M1 Mastère Data Engineering & IA
EFREI Paris Panthéon-Assas Université · Année universitaire 2025-2026
Repo · github.com/Adam-Blf/maintenance-predictive-industrielle